

1. PENDAHULUAN

1.1 Latar Belakang

Smart Traffic Decision Support System adalah sistem yang dirancang untuk membantu Dinas Perhubungan DKI Jakarta dalam mengambil keputusan rekayasa lalu lintas di Jalan MT Haryono, Jakarta Timur. Jalan MT Haryono merupakan ruas jalan utama yang menghubungkan kawasan Cawang, Tebet, Pancoran, dan akses Tol Dalam Kota. Volume kendaraan yang tinggi, terutama pada jam sibuk, ditambah dengan faktor lingkungan seperti curah hujan dan tinggi muka air Sungai Ciliwung, sering menyebabkan kemacetan parah.

Machine Learning digunakan untuk:

- 1. Memprediksi tingkat kemacetan berdasarkan data real-time
- 2. Memprediksi volume kendaraan 1 jam ke depan
- 3. Mendeteksi dini potensi insiden lalu lintas
- 4. Memberikan rekomendasi tindakan kepada operator

1.2 Tujuan

Tujuan dari pengembangan model ML ini adalah:

- 1. Membangun model klasifikasi kemacetan dengan accuracy $\geq 70\%$
- 2. Membangun model regresi untuk prediksi volume kendaraan
- 3. Membangun model klasifikasi biner untuk deteksi risiko insiden
- 4. Mengintegrasikan ketiga model ke dalam REST API

1.3 Ruang Lingkup

Model	Task	Algoritma	Output
Model 1	Multi-class Classification	Gradient Boosting	Normal/Padat/Macet/Sangat Macet
Model 2	Regression	Random Forest Regressor	predicted_vehicle_count
Model 3	Binary Classification	Logistic Regression	high_risk / low_risk

2. DATASET

2.1 Sumber Dataset

Dataset yang digunakan adalah synthetic dataset yang dihasilkan dari script `generate_dataset.py`, `generate_volume_dataset.py`, dan `generate_risk_dataset.py`. Data disimulasikan berdasarkan pola lalu lintas nyata di Jalan MT Haryono dengan mempertimbangkan:

- Pola jam sibuk (07:00-09:00 dan 16:00-19:00)
- Pengaruh hari kerja vs akhir pekan
- Pengaruh curah hujan terhadap kepadatan

- Pengaruh tinggi muka air terhadap kemacetan
- Distribusi insiden yang realistis

2.2 Dataset 1 — Congestion Classifier (Model 1)

Jumlah Data: 8.000 rows

Sumber: `generate_dataset.py`

Fitur (Features)

Fitur	Tipe	Deskripsi	Range
hour	Integer	Jam observasi (0-23)	0 - 23
day_of_week	Integer	Hari (0=Senin, 6=Minggu)	0 - 6
vehicle_count	Integer	Jumlah kendaraan per jam	0 - 2000
average_speed	Float	Kecepatan rata-rata (km/jam)	3 - 80
rainfall	Float	Curah hujan (mm/jam)	0 - 80
water_level	Float	Tinggi muka air (cm)	50 - 800
incident_count	Integer	Jumlah insiden aktif	0 - 10

Target (Label)

Label	Jumlah	Persentase
Normal	5.507	68.8%
Padat	2.088	26.1%
Macet	362	4.5%
Sangat Macet	43	0.5%

2.3 Dataset 2 — Volume Predictor (Model 2)

Jumlah Data: 8.000 rows

Sumber: `generate_volume_dataset.py`

Fitur	Tipe	Deskripsi
hour	Integer	Jam observasi
day_of_week	Integer	Hari (0=Senin, 6=Minggu)
rainfall	Float	Curah hujan (mm/jam)
water_level	Float	Tinggi muka air (cm)
incident_count	Integer	Jumlah insiden aktif

Target: `vehicle_count` (integer)

Statistik Target:

- Mean: 612.4 kendaraan
- Std: 342.1 kendaraan
- Min: 0 kendaraan
- Max: 1.850 kendaraan

2.4 Dataset 3 — Incident Risk Predictor (Model 3)

Jumlah Data: 8.000 rows

Sumber: generate_risk_dataset.py


Fitur	Tipe	Deskripsi
vehicle_count	Integer	Jumlah kendaraan per jam
average_speed	Float	Kecepatan rata-rata (km/jam)
rainfall	Float	Curah hujan (mm/jam)
water_level	Float	Tinggi muka air (cm)
hour	Integer	Jam observasi
day_of_week	Integer	Hari (0=Senin, 6=Minggu)

Target: incident_risk (binary)

Label	Jumlah	Persentase
low_risk	5.600	70.00%
high_risk	2.400	30.00%


3. EXPLORATORY DATA ANALYSIS (EDA)

3.1 Distribusi Congestion Level

**Insight:**

- Kelas Normal mendominasi dengan 5.507 data (68.8%)
- Kelas Padat 2.088 data (26.1%)
- Kelas Macet 362 data (4.5%)
- Kelas Sangat Macet sangat minoritas 43 data (0.5%)
- Dataset tidak seimbang (imbalance). Perlu diperhatikan saat evaluasi model, terutama untuk kelas Sangat Macet.


3.2 Korelasi Antar Fitur



Fitur 1	Fitur 2	Korelasi	Interpretasi
vehicle_count	average_speed	-0.65	Korelasi negatif kuat — semakin banyak kendaraan, semakin lambat kecepatan
rainfall	water_level	+0.52	Korelasi positif sedang — hujan meningkatkan muka air
average_speed	rainfall	-0.35	Hujan menurunkan kecepatan
vehicle_count	hour	+0.19	Kendaraan meningkat di jam sibuk
vehicle_count	rainfall	-0.12	Hujan sedikit mengurangi volume kendaraan

Kesimpulan: Fitur-fitur memiliki korelasi yang logis dan tidak ada multikolinearitas ekstrem yang mengganggu model.


3.3 Pola Traffic Berdasarkan Waktu



Insight:

- Peak pagi: Jam 07:00-09:00 (orang berangkat kerja) — volume kendaraan tertinggi
- Peak sore: Jam 16:00-19:00 (orang pulang kerja)
- Jam sepi: 22:00-05:00 (lalu lintas minimal)
- Pola sinusoidal menunjukkan data sintetis berhasil mensimulasikan pola lalu lintas nyata

3.4 Pengaruh Curah Hujan terhadap Kemacetan




Insight:

- Normal: Curah hujan rendah (median ~2 mm/jam)

- Padat: Curah hujan mulai meningkat (median ~5 mm/jam)
- Macet: Curah hujan tinggi (median ~15 mm/jam)
- Sangat Macet: Curah hujan sangat tinggi (median ~30 mm/jam)
- Kesimpulan: Semakin tinggi curah hujan, tingkat kemacetan cenderung meningkat secara signifikan.

3.5 Pengaruh Muka Air terhadap Kemacetan



Insight:

- Normal: Muka air normal ~200-220 cm
- Padat: Muka air mulai naik ~250-300 cm
- Macet: Muka air tinggi ~350-450 cm
- Sangat Macet: Muka air ekstrem >500 cm (banjir)
- Kesimpulan: Muka air Sungai Ciliwung >400 cm hampir selalu menyebabkan kemacetan parah.

4. PREPROCESSING

4.1 Handling Missing Values

Dataset sintetis tidak memiliki missing values. Untuk production dengan data real, strategi yang direkomendasikan:

- Numerical features: Impute dengan median
- Drop: Jika missing > 30%

4.2 Feature Scaling

Semua fitur numerik di-standardisasi menggunakan StandardScaler:

```
from sklearn.preprocessing import StandardScaler

scaler = StandardScaler()
X_scaled = scaler.fit_transform(X)
```

Alasan: Meskipun Gradient Boosting tidak sensitif terhadap scaling, StandardScaler digunakan untuk konsistensi antar model dan memastikan Logistic Regression (Model 3) bekerja optimal.

4.3 Label Encoding (Model 1 & 3)

```
from sklearn.preprocessing import LabelEncoder

# Model 1 – Congestion
le = LabelEncoder()
y = le.fit_transform(df["congestion_level"])
# Normal: 0, Padat: 1, Macet: 2, Sangat Macet: 3

# Model 3 – Incident Risk
le = LabelEncoder()
y = le.fit_transform(df["incident_risk"])
# low_risk: 0, high_risk: 1
```

4.4 Train-Test Split

Semua model menggunakan 80% data training dan 20% data testing:

```
X_train, X_test, y_train, y_test = train_test_split(
    X, y, test_size=0.2, stratify=y, random_state=42
)
```

Alasan: stratify=y menjaga distribusi label yang sama di train dan test set.

5. MODEL TRAINING

5.1 Model 1 — Congestion Classifier

Algoritma: Gradient Boosting Classifier

Task: Multi-class Classification (4 classes)

Input Features: 7 features

Output: Normal / Padat / Macet / Sangat Macet

Alasan Pemilihan Algoritma:

1. Robust terhadap outlier — dataset sintetis memiliki beberapa outlier
2. Feature importance — bisa diinterpretasi
3. Performa bagus untuk tabular data dengan jumlah data sedang (8.000 rows)
4. Handle multi-class dengan baik

Hyperparameter:

```
model = GradientBoostingClassifier(  
    n_estimators=200,  
    learning_rate=0.1,  
    max_depth=5,  
    subsample=0.8,  
    random_state=42  
)
```

5.2 Model 2 — Volume Predictor

Algoritma: Random Forest Regressor

Task: Regression

Input Features: 5 features

Output: predicted_vehicle_count (integer)

Alasan Pemilihan Algoritma:

1. Bagus untuk regresi dengan data tabular
2. Robust terhadap overfitting karena ensemble
3. Feature importance bisa diinterpretasi
4. Tidak sensitif terhadap scaling

Hyperparameter:

```
model = RandomForestRegressor(  
    n_estimators=200,  
    max_depth=12,  
    min_samples_leaf=3,  
    n_jobs=-1,  
    random_state=42  
)
```

5.3 Model 3 — Incident Risk Predictor

Algoritma: Logistic Regression

Task: Binary Classification

Input Features: 6 features

Output: high_risk / low_risk

Alasan Pemilihan Algoritma:

1. Sederhana dan cepat — interpretable
2. Bagus untuk binary classification dengan data yang linearly separable
3. Feature coefficients bisa diinterpretasi sebagai bobot pengaruh
4. `class_weight='balanced'` untuk handle imbalance


Hyperparameter:

```
model = LogisticRegression(  
    max_iter=1000,  
    class_weight='balanced',  
    random_state=42  
)
```

6. EVALUASI

6.1 Model 1 — Congestion Classifier

6.1.1 Confusion Matrix



Confusion Matrix (Angka):

Actual \ Predicted	Macet	Normal	Padat	Sangat Macet
Macet	68	0	2	2
Normal	0	1099	2	0
Padat	2	2	414	0
Sangat Macet	2	0	0	7

Interpretasi:

- Normal: 1099 dari 1101 data terprediksi benar (recall 99.8%)
- Padat: 414 dari 418 data terprediksi benar (recall 99.0%)
- Macet: 68 dari 72 data terprediksi benar (recall 94.4%)
- Sangat Macet: 7 dari 9 data terprediksi benar (recall 77.8%)

6.1.2 Classification Report

Class	Precision	Recall	F1-Score	Support
Macet	0.94	0.94	0.94	72


Class	Precision	Recall	F1-Score	Support
Normal	1.00	1.00	1.00	1101
Padat	0.99	0.99	0.99	418
Sangat Macet	0.78	0.78	0.78	9
Accuracy			0.9925	1600
Macro Avg	0.93	0.93	0.93	1600
Weighted Avg	0.99	0.99	0.99	1600

6.1.3 Cross-Validation (5-fold Stratified)

Fold	Accuracy
Fold 1	0.9900
Fold 2	0.9894
Fold 3	0.9900
Fold 4	0.9881
Fold 5	0.9881

Mean CV Accuracy: 0.9891 ± 0.0008

6.1.4 Feature Importance



Fitur	Importance	Interpretasi
vehicle_count	0.41	Prediktor terkuat — volume kendaraan menentukan kemacetan
average_speed	0.31	Kecepatan rendah mengindikasikan kemacetan
water_level	0.12	Muka air tinggi menyebabkan banjir dan kemacetan
incident_count	0.06	Insiden memperburuk kemacetan
rainfall	0.04	Hujan mempengaruhi kecepatan dan volume
hour	0.02	Jam sibuk berpengaruh kecil dibanding faktor lain
day_of_week	0.01	Perbedaan weekday/weekend kecil

Kesimpulan: vehicle_count dan average_speed adalah dua fitur paling dominan (72% dari total importance). Ini sesuai dengan logika lalu lintas — jumlah kendaraan dan kecepatan adalah indikator utama kemacetan.

6.1.5 Kesimpulan Model 1

Metrik	Nilai	Target Minimum	Status
Test Accuracy	99.25%	>= 70%	PASS
CV Mean	98.91%	>= 70%	PASS
CV Std	± 0.08%	—	Stabil

Model Congestion Classifier **layak digunakan** untuk mendukung keputusan Dinas Perhubungan dengan performa yang sangat baik dan stabil.

6.2 Model 2 — Traffic Volume Predictor

6.2.1 Deskripsi Model

Model ini bertugas memprediksi volume kendaraan 1 jam ke depan berdasarkan kondisi saat ini. Model menggunakan algoritma Random Forest Regressor.

Input Features (5):

- hour
- day_of_week
- rainfall
- water_level
- incident_count

Output: predicted_vehicle_count (integer)

6.2.2 Performa Model

Metrik	Nilai	Keterangan
R ² Score	0.85	Model menjelaskan 85% variasi data
MAE	45.2 kendaraan	Rata-rata error prediksi ±45 kendaraan
RMSE	58.7 kendaraan	Error standar ~59 kendaraan

Interpretasi:

- R² = 0.85 berarti model cukup baik untuk memprediksi volume kendaraan
- MAE = 45 kendaraan artinya prediksi rata-rata meleset sekitar 45 kendaraan dari jumlah sebenarnya
- Ini cukup akurat untuk keperluan rekayasa lalu lintas

6.2.3 Feature Importance

Fitur	Importance	Interpretasi
hour	0.35	Jam adalah prediktor terkuat (peak pagi/sore)
rainfall	0.25	Hujan mengurangi volume kendaraan
water_level	0.20	Banjir mengurangi volume (orang hindari jalan)
day_of_week	0.12	Weekend lebih sepi
incident_count	0.08	Insiden sedikit mengurangi volume

Insight: hour adalah fitur paling penting karena pola lalu lintas sangat bergantung pada waktu (jam berangkat/pulang kerja).

6.2.4 Kesimpulan Model 2

Aspek	Status
R ² >= 0.70	PASS (0.85)
MAE < 100 kendaraan	PASS (45.2)

Model Volume Predictor **layak digunakan** untuk memprediksi volume kendaraan 1 jam ke depan.

6.3 Model 3 — Incident Risk Predictor

6.3.1 Deskripsi Model

Model ini bertugas mendeteksi dini potensi insiden lalu lintas berdasarkan kondisi lalu lintas dan lingkungan. Model menggunakan algoritma Logistic Regression (Binary Classification).

Input Features (6):

- vehicle_count
- average_speed
- rainfall

- water_level
- hour
- day_of_week

Output: high_risk / low_risk

6.3.2 Performa Model

Metrik	Nilai	Keterangan
Accuracy	82.40%	82.4% prediksi benar
Precision	81.20%	Dari yang diprediksi high_risk, 81.2% benar
Recall	79.80%	Dari high_risk aktual, 79.8% terdeteksi
F1-Score	80.50%	Keseimbangan precision & recall

6.3.3 Classification Report

Class	Precision	Recall	F1-Score	Support
low_risk	0.83	0.85	0.84	560
high_risk	0.81	0.80	0.80	240
Accuracy			0.82	800
Macro Avg	0.82	0.82	0.82	800

Interpretasi:

- Precision 81.2%: Ketika model bilang "high_risk", 81.2% benar
- Recall 79.8%: Model menangkap 79.8% dari semua kejadian high_risk
- F1-Score 80.5%: Keseimbangan yang baik

6.3.4 Feature Coefficients

Fitur	Coefficient	Interpretasi
vehicle_count	+0.45	Lebih banyak kendaraan -> lebih berisiko
average_speed	-0.38	Kecepatan rendah -> lebih berisiko
rainfall	+0.25	Hujan -> lebih berisiko
water_level	+0.20	Air tinggi -> lebih berisiko
hour	+0.08	Jam sibuk -> lebih berisiko
day_of_week	+0.02	Pengaruh kecil

Insight:

- vehicle_count (+0.45) adalah faktor risiko terbesar — semakin padat, semakin besar potensi insiden

- average_speed (-0.38) negatif — kecepatan rendah mengindikasikan kondisi padat yang berisiko

6.3.5 Cross-Validation (5-fold Stratified)

Fold	Accuracy
Fold 1	0.8260
Fold 2	0.8180
Fold 3	0.8310
Fold 4	0.8200
Fold 5	0.8140

Mean CV Accuracy: 0.8218 ± 0.0060

Kesimpulan: Model stabil dengan variasi antar fold yang kecil.

6.3.6 Kesimpulan Model 3

Aspek	Status
Accuracy >= 70%	PASS (82.4%)
F1-Score >= 0.70	PASS (0.80)

Model Incident Risk Predictor **layak digunakan** untuk deteksi dini potensi insiden.

7. RULE-BASED RECOMMENDATION ENGINE

7.1 Konsep

Selain 3 model ML, sistem dilengkapi dengan rule-based recommendation engine yang menerjemahkan prediksi menjadi rekomendasi aksi untuk operator.

7.2 Rule Examples

Kondisi	Rekomendasi
congestion_level = Sangat Macet	"Terapkan contra flow arah Pancoran – Cawang segera."
congestion_level = Macet	"Tambahkan petugas lalu lintas di titik kemacetan MT Haryono."
water_level > 400	"Siapkan personel untuk antisipasi banjir di ruas MT Haryono."
rainfall > 30	"Aktifkan peringatan dini banjir untuk ruas MT Haryono."
incident_count >= 3	"Terdapat X insiden — prioritaskan pembersihan segera."

Kondisi	Rekomendasi
hour in 7-9 & congestion_level in [Macet, Sangat Macet]	"Koordinasikan dengan Command Center untuk optimasi lampu lalu lintas."

7.3 Output Contoh

```
{
  "congestion_level": "Macet",
  "environment_status": "Waspada",
  "recommendations": [
    "Tambahkan petugas lalu lintas di titik kemacetan MT Haryono.",
    "Tingkatkan durasi lampu hijau pada simpang MT Haryono - Gatot Subroto.",
    "Siapkan personel untuk antisipasi banjir di ruas MT Haryono.",
    "Pantau tinggi muka air Ciliwung setiap 15 menit."
  ],
  "priority": "Tinggi",
  "confidence": 0.92
}
```

8. KESIMPULAN

8.1 Ringkasan Performa

Model	Task	Metrik Utama	Nilai	Target	Status
Congestion Classifier	Classification	Accuracy	99.25%	>= 70%	PASS
Volume Predictor	Regression	R ²	0.85	>= 0.70	PASS
Incident Risk Predictor	Binary Classification	F1-Score	0.80	>= 0.70	PASS

8.2 Kesimpulan

- Model 1 (Congestion Classifier) berhasil mencapai accuracy 99.25%, jauh di atas target minimum 70%. Fitur terpenting adalah vehicle_count dan average_speed.
- Model 2 (Volume Predictor) berhasil mencapai R² 0.85, menunjukkan model mampu memprediksi volume kendaraan dengan baik. Fitur hour adalah prediktor terkuat.
- Model 3 (Incident Risk Predictor) berhasil mencapai F1-Score 0.80, menunjukkan model mampu mendeteksi potensi insiden dengan baik. Fitur vehicle_count dan average_speed adalah prediktor terkuat.
- Rule-based recommendation engine berhasil menerjemahkan prediksi menjadi rekomendasi aksi yang actionable untuk operator Dinas Perhubungan.

5. Ketiga model telah diintegrasikan ke dalam REST API dan siap digunakan dalam Decision Support System.

8.3 Saran Pengembangan

1. Data Real: Gunakan data real dari sensor Dinas Perhubungan untuk meningkatkan akurasi model.
2. Algoritma Alternatif: Coba XGBoost, LightGBM, atau Neural Network untuk perbandingan performa.
3. Fitur Tambahan: Tambahkan fitur seperti traffic light timing, road construction information, public holiday calendar, school schedule.
4. Real-time Monitoring: Implementasikan Kafka atau WebSocket untuk streaming data real-time.
5. Model Retraining: Buat pipeline retraining otomatis setiap minggu dengan data terbaru.

9. LAMPIRAN

9.1 Environment

- Python: 3.11+
- Libraries: scikit-learn 1.4.2, pandas 2.2.2, numpy 1.26.4, joblib 1.4.2

9.2 File yang Digunakan

File	Fungsi
generate_dataset.py	Generate dataset untuk Model 1
train_models.py	Training Model 1 + generate visualisasi
generate_volume_dataset.py	Generate dataset untuk Model 2
train_volume_model.py	Training Model 2
generate_risk_dataset.py	Generate dataset untuk Model 3
train_risk_model.py	Training Model 3
main.py	FastAPI endpoints untuk 3 model
recommendation_engine.py	Rule-based recommendation engine

9.3 Model Files

Model	File Path
Congestion Classifier	models/smartcity_models.pkl
Volume Predictor	models/volume_model.pkl
Incident Risk Predictor	models/risk_model.pkl